


上次问题的解答：

LOAM 是用旋转的 2D 激光来构建 3D 点云，怎样消除点云的畸变（形变）？

是用两条平行的线程解决此类问题，Odometry 线程只是做简单的 registration 来估计 lidar 的行驶速度，再将此速度传给 mapping 线程。Mapping 线程根据此速度与时间差值修正点云的畸变，再通过 registration 来构建地图。Registration 可以得到新的 transform。如下图所示：



论文：Petrovskaya A, Thrun S. **Model based vehicle detection and tracking for autonomous urban driving**[J]. Autonomous Robots, 2009, 26(2):123-139.


一. 引言

这篇论文是由 Sebastian 团队完成。该团队获得了 2007 年 DARPA 城市挑战赛的亚军，也是 Google 无人车项目的先行者。移动车辆的检测与跟踪是无人驾驶的关键问题之一。这篇论文详细地论述了该团队是如何解决此类问题，有很高的借鉴意义。

二. 方法简介

1. 2D virtual scan generation

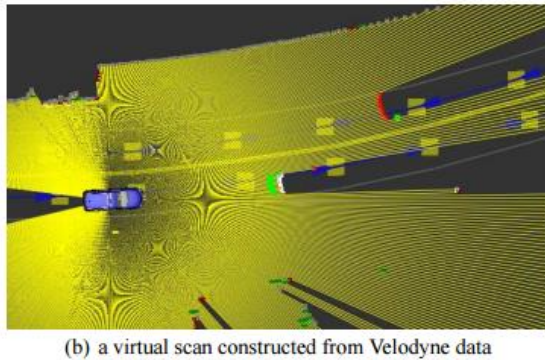

该论文使用的传感器是 Velodyne 64 线激光，因此首要的问题是如何在 3D 的激光点云中分别出哪些点是地面上的点，以及障碍物的点。文中使用的是一种基于角度的检测方法，如下图所示：



如果两个线段 AB 与 BC 之间的夹角 α 大于零（即 $\cos \alpha < 1$ ），可以认为 C 点为障碍物点，而 A 点与 B 点则为地面上的点。如果 BC 的长度较长（大于 1m ），则认为 C 点不是我们关心的车辆上的点，或许只是偶尔飞过的小鸟。根据这种简单而有效的推断，可以将车辆等障碍物分割出来。

为了简化问题，我们需要将 3D 点云简化成一个 2D 问题，这就需要我们生成虚拟的 2D 激光（virtual scan）。Virtual scan 根据角度将空间划分成 N 个小角度，而每个小角度只记录与传感器最近的距离信息，这样就将 64 维的激光信息压缩成 1 维。因为我们只关心距离最近的障碍物点，而不关心这个障碍物表面的具体点云分布是什么。这样大大减少了计算量。

有了最近信息后，可以在一个小角度上将空间划分为三个区域：free space、occupied space 以及 occluded space。如下图所示：



最终所得到的 t 时刻的 virtual scan 即为观测值 Z_t ，包含 N 个角度的局部观测值 z_i 。

2. 车辆的动态模型与观测模型

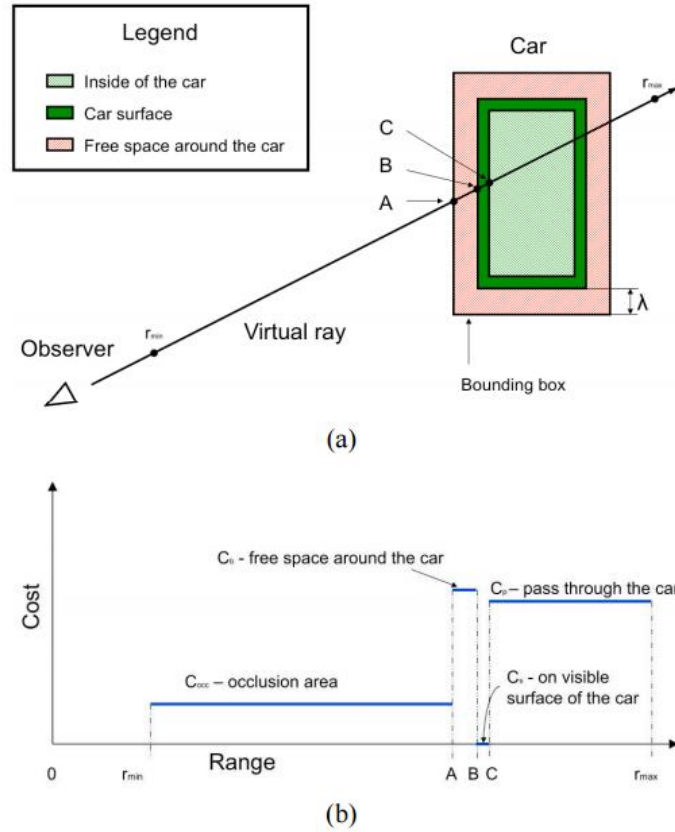
无人车在道路上行驶的过程中，车辆是移动的，无人车本身也是移动的。因此所观测的车辆模型不能用简单的长度与宽度来衡量，文中提出

用锚点（anchor point）来描述车辆的几何信息。假设一个车辆在自身坐标系下， t 时刻相对于 $t-1$ 时刻的二维位移为 $C = (C_x, C_y)$ ，则该车辆在该时刻的几何模型为 $G = (W, L, C_x, C_y)$ 。

在其他传感器的帮助下，无人车自身的定位精度在 **1m** 以内，这种误差可以忽略。对于每个车辆，我们估计它在 t 时刻的位置与朝向，即 $X_t = (x_t, y_t, \theta_t)$ ，该量又与上一时刻的位姿以及速度（假设短时间内匀速运动）相关，用概率描述即为 $p(X_t | X_{t-1}, v_t)$ 。结合观测值 Z_t ，可以得到观测模型：

$$p(Z_t | X_t, G)$$

为了计算上式，需要对观测模型进行建模，建模如下图所示：



如果 Virtual scan 包含 N 个射线，那么这些似然因子可以累积起来，即：

$$p(Z | G, X) = \prod_{i=1}^N p(z_i | G, X)$$

对于每束激光射线，用高斯分布来描述车辆检测的似然性：

$$P(z_i | G, X) = \eta_i \exp\{-\frac{c_i^2}{\sigma_i^2}\}$$

上式中， c 与 σ 的值根据 **Range** 的分布来决定，车辆表面与车辆内部的似然性是不一样的。

3. 目标跟踪与预测

对于多目标跟踪，一种常用的方法是用 **EKF** 来估计，但是当车辆的数目很多时，计算量复杂度就会很大。文中采用的是简化版的 **Rao-Blackwellized** 粒子滤波方法，这与传统的自定位方法很类似，这不过待估计的量不是定位，而是每个车辆的 X 、 v 以及 G 。文中有较为详细的推导，这里就不赘述了。

三. 实验结果与总结

作为 **DARPA UGC** 项目的亚军，该论文中的方法已经得到了很好的验证，文中提供的 **tracking** 结果是 **TP(True Positive) = 97%**，在不使用 **learning** 的情况下，达到如此好的效果实属不易。这篇论文延续了 **Thrun** 利用概率解决自定位问题的风格，和《**Probabilistic Robotics**》书中一样，对观测模型建模等等。

这篇文章完成于 2008 年，距离现在快过去十年了。十年的时间内，物体检测与跟踪已经被各种 **learning** 方法统治，计算机视觉也逐步替代了激光作为检测的工具。但是激光传感器也有自身独特的优势，比如对光照变化的鲁棒性，在深度方向的精确测量等等，如果将两者结合起来互补，可以得到很好的效果。